

Μηχανική Μάθηση

7ο εξάμηνο Ακαδημαϊκό έτος 2023-2024

Ονοματεπώνυμο: Κούτρας Ιωάννης- Παναγιώτης

A.M.: 03120130

Email-address: ioanniskoutras2002@gmail.com

1η Σειρά Ασκήσεων

Οι λύσεις είναι ως επί το πλείστον χειρόγραφες, ενώ συμπεριλαμβάνονται και κομμάτια κώδικα στα σημεία στα οποία χρησιμοποιήθηκαν.

Άσκηση 1.1 (Linear and Ridge Regression)

Όπως προβλέπεται και στη σημείωση της εκφώνησης για την άσκηση 1.1, για τη λύση παραθέτω τον κώδικα (Python) που χρησιμοποιήθηκε καθώς και τα ζητούμενα αποτελέσματα και σχόλια που τον συνοδεύουν.

- Normalize data:

```
import pandas as pd

data = pd.read_csv('data.csv', sep=';')
quality = data['quality']
print(f' Quality range: {quality.min()} - {quality.max()}')

# normalize the data
normed = data.copy()
for attr in normed.columns.difference(['quality']):
    normed[attr] -= data[attr].mean()
    normed[attr] /= data[attr].std()

# save to csv
normed.to_csv('data_normed.csv')
```

➔ Quality range: 3 - 8

- Find the correlation coefficient between pH and sulphates (no need for division because of unit/normalized variances):

```
import pandas as pd
import numpy as np

data = pd.read_csv('data_normed.csv')

# with build ins
r9_10 = data.corr()['pH']['sulphates']

# without build ins
cov_ph_sul = np.mean((data['pH'] - data['pH'].mean()) * (data['sulphates'] - data['sulphates'].mean()))
cov_ph_sul, r9_10
```

➔ (-0.19652462068942095, -0.19664760230437037)

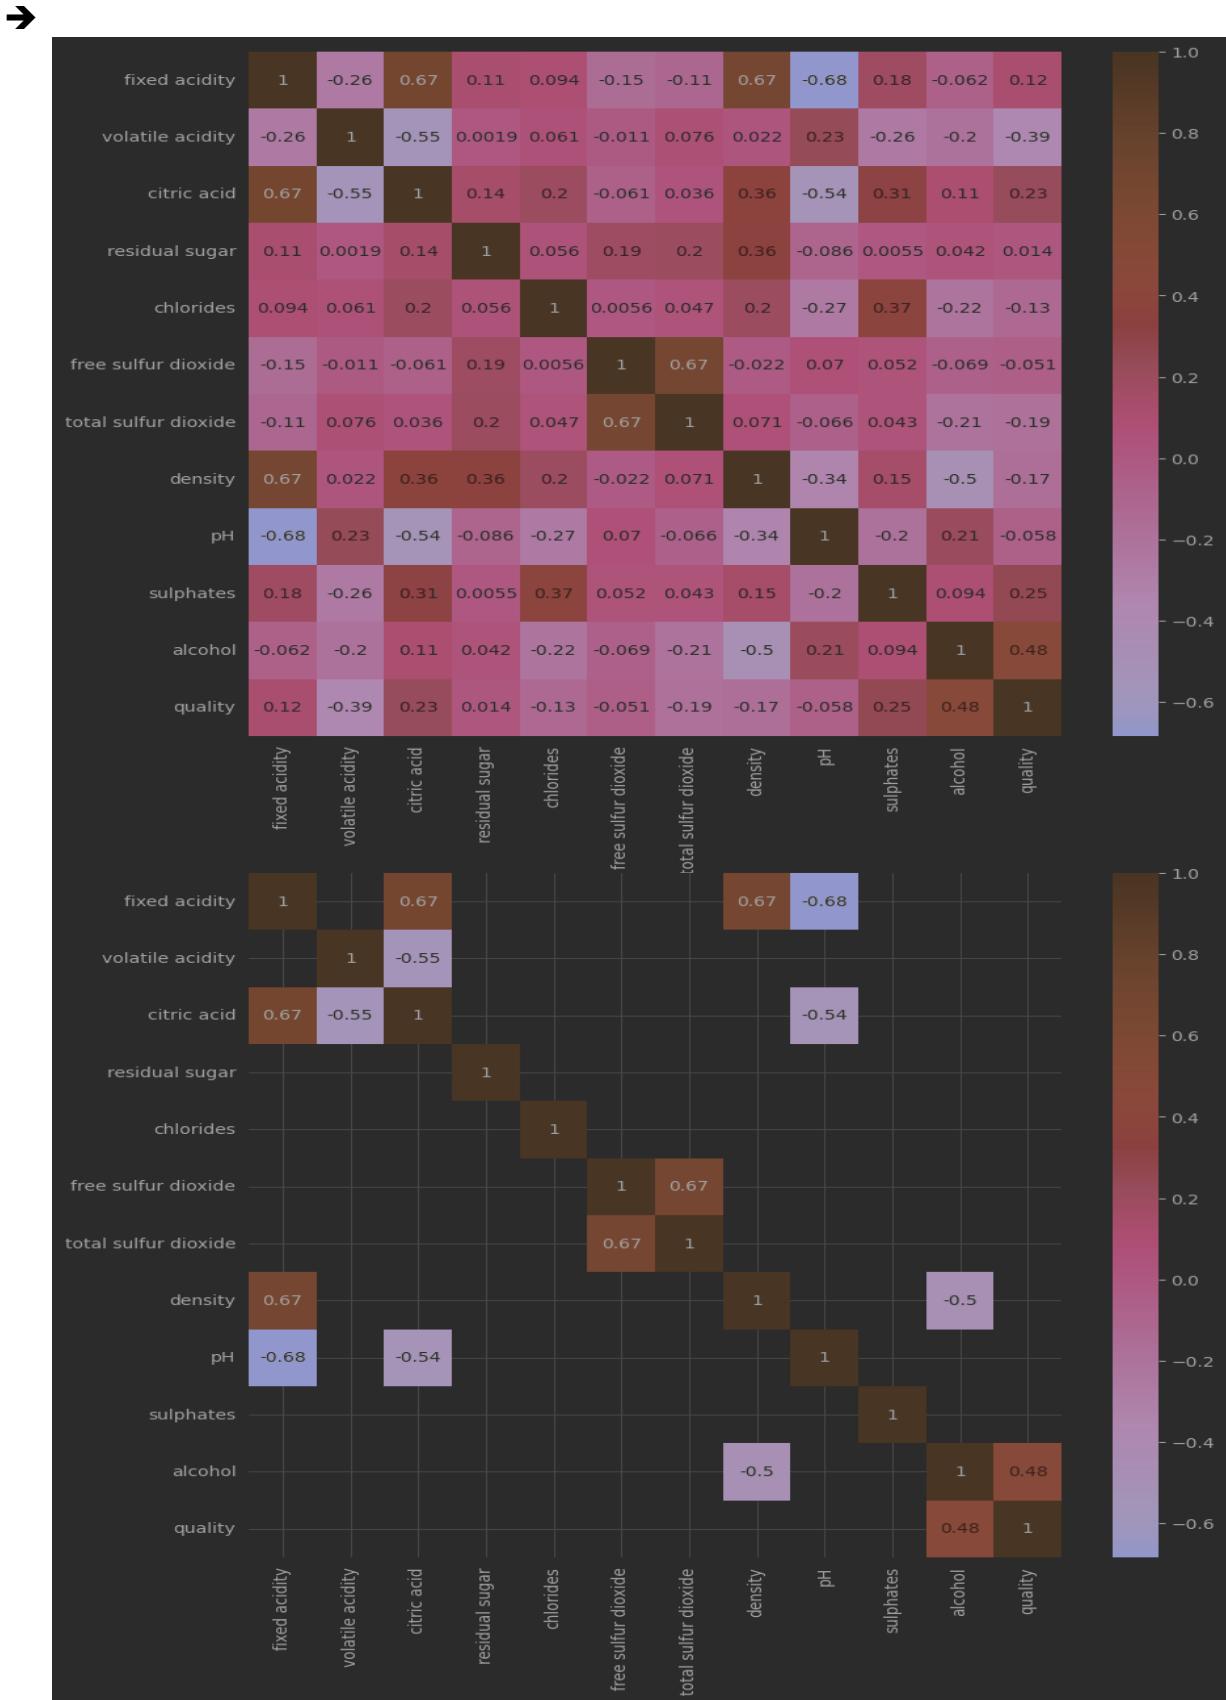
- Scatter plots of Cov using the seaborn library (specifically heatmaps):

```
import seaborn as sns
import matplotlib.pyplot as plt

corr = data.corr()

# create scatter plots of all the pairs
plt.figure(figsize=(10, 20))
plt.subplot(211)
sns.heatmap(corr, annot=True)

high_corr = corr.where(abs(corr) > 0.4)
plt.subplot(212)
sns.heatmap(high_corr, annot=True)
plt.show()
```



Σχόλια- Παρατηρήσεις: Από το heatmap παρατηρούμε ότι τα ζεύγη με υψηλό correlation είναι:

- (fixed acidity, citric acid, +), (fixed acidity, density, +), (fixed acidity, pH, -)
- (volatile acidity, citric acid, -)
- (pH, citric acid, -)
- (total sulfur dioxide, free sulfur dioxide, +)
- (alcohol, density, -)
- (quality, alcohol, +)

```
X = np.asarray(data.iloc[:100, :-1])
Y = np.asarray(data.iloc[:100, -1])
X_test = np.asarray(data.iloc[100:150, :-1])
Y_test = np.asarray(data.iloc[100:150, -1])
```

Για το επόμενο μέρος χρησιμοποιούμε τους τύπους για linear και ridge regression από τα slides του μαθήματος , δηλαδή:

Linear Regression weight formula:

$$\mathbf{w} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \Rightarrow \mathbf{w} = \mathbf{X}^+ \mathbf{y}$$

Ridge Regression weight formula:

$$\mathbf{w} = (\mathbf{X}^\top \mathbf{X} + \lambda \cdot \mathbf{I})^{-1} \cdot \mathbf{X}^\top \cdot \mathbf{y}$$

- Setting up the calculations, data:

```
import numpy as np
from numpy.linalg import inv

# Linear Regression
w = inv(X.T @ X) @ X.T @ Y

# Ridge Regression
w_r = lambda l: np.linalg.inv(X.T @ X + l * np.eye(X.shape[1])) @ X.T @ Y
w_r_10, w_r_100, w_r_200 = w_r(10), w_r(100), w_r(200)
```

- Weight plotting:

```
import matplotlib.pyplot as plt
plt.figure(figsize=(10, 6))
plt.plot(w, label='Linear Regression (w)')
```

```

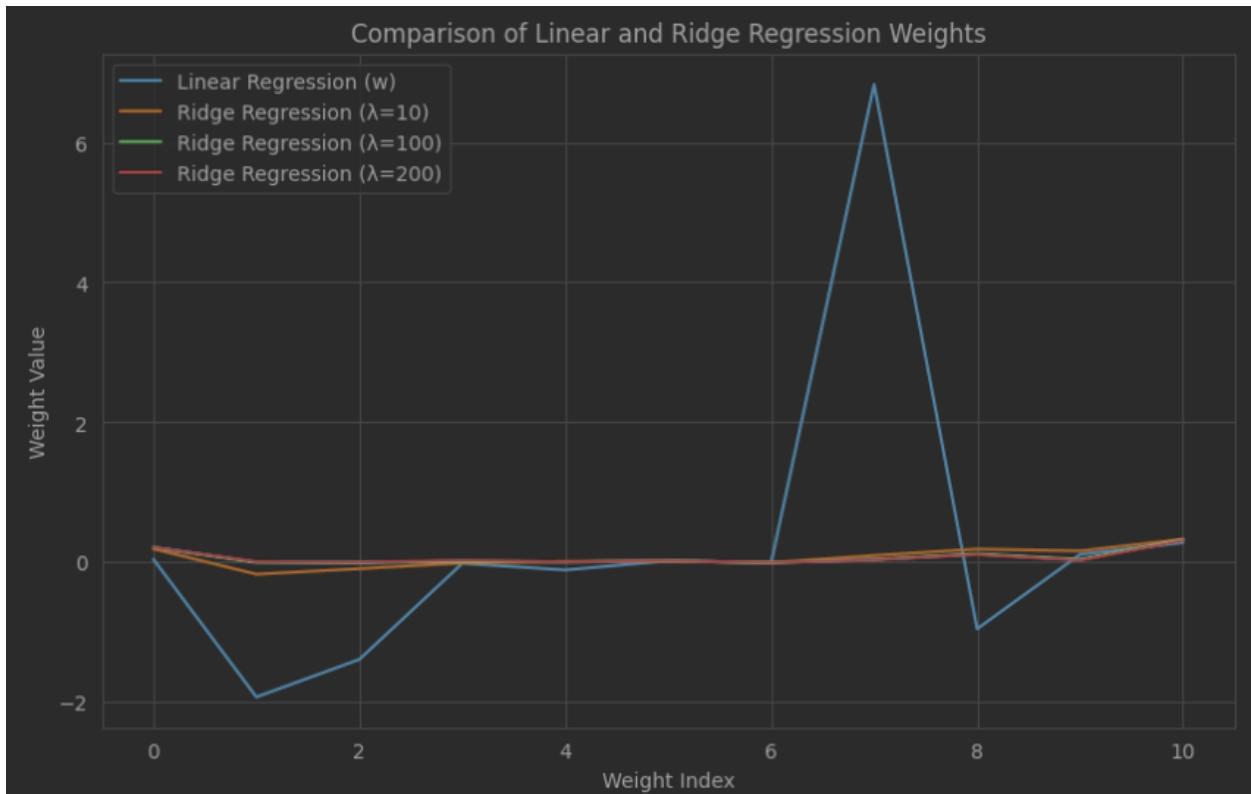
plt.plot(w_r_10, label='Ridge Regression (\lambda=10)')
plt.plot(w_r_100, label='Ridge Regression (\lambda=100)')
plt.plot(w_r_200, label='Ridge Regression (\lambda=200)')

plt.title('Comparison of Linear and Ridge Regression Weights')
plt.xlabel('Weight Index')
plt.ylabel('Weight Value')

plt.legend()

plt.show()

```



Σχόλια- Παρατηρήσεις:

-Μικρότερο λ συνεπάγεται μικρότερες τιμές των βαρών. Αυτό συμβαίνει διότι το Ridge Regression χρησιμοποιεί L2 loss.

-Τα attributes που δεν έχουν υψηλό correlation έχουν προφανώς χαμηλές τιμές βαρών, συνεπώς δεν έχουν σημαντική επιρροή στο αποτέλεσμα.

- Calculation of RMSE:

Χρησιμοποιήσαμε τον τύπο

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$$

```
def calc_rmse(X, Y):
    y_pred = [w_i @ X.T for w_i in [w, w_r_10, w_r_100, w_r_200]]
    rmse = [np.sqrt(sum(Y - y_i) ** 2) / len(y_pred) for y_i in y_pred]
    return rmse

# Train
print(f'Train RMSE:\n{calc_rmse(X, Y)}\n\nTest RMSE:\n{calc_rmse(X_test,
Y_test)}')
```

➔ Train RMSE:

[0.00027317616972866166, 0.2433519846861174, 0.9709019133401842,
1.722949291019658]

Test RMSE:

[2.279020633087578, 1.5609199581132982, 1.826274308097586,
2.2584927200838147]

Άσκηση 1.2 (Multivariate Gaussian Distribution)

Άσκηση 1.2 (Multivariate Gaussian Distribution)

$$(a) \mathbf{x} = [x_1, x_2]^T, \mathbf{x} \sim N(\boldsymbol{\mu}, \Sigma)$$

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$$

τα δείγματα ή υπόσχιση συνήργαν νυνούσιας μεταβλητών
(όπως) $p(x_1 | x_2 = a)$ είναι Gaussian $N(\mu', \sigma'^2)$

$$\text{όπου } \mu' = \mu_1 + \frac{\sigma_{12}}{\sigma_2^2} (a - \mu_2), \sigma'^2 = \frac{\sigma_1^2 \sigma_2^2 - \sigma_{12}^2}{\sigma_2^2}$$

$$\text{Έχουμε: } p(x_1 | x_2 = a) \triangleq \frac{p(x_1, x_2) | x_2 = a}{p(x_2 = a)}$$

$$\cdot p(x_1, x_2) | x_2 = a = \frac{1}{2\pi\sqrt{|\Sigma|}} \cdot \exp \left\{ -\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ a - \mu_2 \end{bmatrix} \Sigma^{-1} \begin{bmatrix} x_1 - \mu_1 \\ a - \mu_2 \end{bmatrix} \right\}$$

$$\text{με } |\Sigma| = \det \Sigma = \sigma_1^2 \sigma_2^2 - \sigma_{12}^2 \text{ και } \Sigma^{-1} = \frac{1}{\sigma_1^2 \sigma_2^2 - \sigma_{12}^2} \cdot \begin{bmatrix} \sigma_2^2 & -\sigma_{12} \\ -\sigma_{12} & \sigma_1^2 \end{bmatrix}$$

$$\cdot x_1 \sim N(\mu_1, \sigma_1^2) \text{ , απα } p(x_2 = a) = \frac{1}{\sigma_2 \sqrt{2\pi}} \exp \left\{ -\frac{(a - \mu_2)^2}{2\sigma_2^2} \right\}$$

Συνεπής τις δύο όψεις να προφέ:

$$p(x_1 | x_2 = a) = \frac{1}{2\pi\sqrt{|\Sigma|}} \cdot \exp \left\{ -\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ a - \mu_2 \end{bmatrix} \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_1 \\ a - \mu_2 \end{bmatrix} \right\}$$

$$\cdot \frac{1}{\sigma_2 \sqrt{2\pi}} \exp \left\{ -\frac{(a - \mu_2)^2}{2\sigma_2^2} \right\}$$

$$\Rightarrow p(x_1 | x_2 = a) = \frac{1}{\sqrt{2\pi} \cdot \sqrt{(\sigma_1^2 \sigma_2^2 - \sigma_{12}^2)}} \cdot \exp \left\{ -\frac{1}{2} \cdot \frac{1}{\sigma_1^2 \sigma_2^2 - \sigma_{12}^2} \begin{bmatrix} x_1 - \mu_1 \\ a - \mu_2 \end{bmatrix}^T \begin{bmatrix} \sigma_1^2 & -\sigma_{12} \\ -\sigma_{12} & \sigma_2^2 \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 \\ a - \mu_2 \end{bmatrix} \right\}$$

Εγκενίωσας τις πράξεις μεταφορές:

$$p(x_1 | x_2 = \alpha) = \frac{1}{\sqrt{\left(\frac{\sigma_1^2 \sigma_2^2 - \sigma_{12}^2}{\sigma_2^2}\right) \cdot 2\pi}} \cdot \exp \left\{ -\frac{(x_1 - (\mu_1 + \sigma_{12}(\alpha - \mu_2)))^2}{2 \cdot \left(\frac{\sigma_1^2 \sigma_2^2 - \sigma_{12}^2}{\sigma_2^2}\right)} \right\}$$

συντονώντας αν $\mu' = \mu_1 + \sigma_{12}(\alpha - \mu_2)$ και $\sigma'^2 = \frac{\sigma_1^2 \sigma_2^2 - \sigma_{12}^2}{\sigma_2^2}$

τότε $p(x_1 | x_2 = \alpha) = \frac{1}{\sigma' \sqrt{2\pi}} \cdot \exp \left(-\frac{(x_1 - \mu')^2}{2\sigma'^2} \right)$

άπα στη σημερινή $p(x_1 | x_2 = \alpha)$ είναι Gaussian $N(\mu', \sigma'^2)$

(b) Χρηματοδότησας τις αριθμ. ανά τη σελ. 15 των slides του μαθήματος έχουμε: $(x_1 | x_2 = \alpha) \sim N(\hat{\mu}, \hat{\Sigma})$, δημο

$$\hat{\mu} = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\alpha - \mu_2), \quad \hat{\Sigma} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$$

$$\cdot \hat{\mu} = \begin{bmatrix} -2 \\ 0 \end{bmatrix} + \begin{bmatrix} 0,5 \\ 1 \end{bmatrix} \cdot 3^{-1} \cdot (-1) = \begin{bmatrix} -6,5 \\ -1,5 \end{bmatrix}$$

$$\cdot \hat{\Sigma} = \begin{bmatrix} 1 & 0,8 \\ 0,8 & 2 \end{bmatrix} - \begin{bmatrix} 0,5 \\ 1 \end{bmatrix} \cdot 3^{-1} \begin{bmatrix} 0,5 & 1 \end{bmatrix} = \begin{bmatrix} 2,75 & 1,9 \\ 1,9 & 5 \end{bmatrix} .$$

Σημείωση $p(x_1, x_2 | x_3 = 1) = \frac{1}{2\pi \sqrt{|\hat{\Sigma}|}} \exp \left\{ -\frac{1}{2} (x - \hat{\mu})^\top \hat{\Sigma}^{-1} (x - \hat{\mu}) \right\}$

για $x = [x_1, x_2]^\top$, $\hat{\mu} = -1 \begin{bmatrix} 6,5 \\ 1 \end{bmatrix}$, $\hat{\Sigma} = \frac{1}{3} \begin{bmatrix} 2,75 & 1,9 \\ 1,9 & 5 \end{bmatrix}$

(j) Θα χρειαστούμε πρώτα ένα γραμμικό μετασχηματισμό
 $x' = Ax$ έτσι ώστε να μπορούμε να εργαστούμε σύντομα και στο (B)
 ερώτημα. Δηλαδή να είναι εριτός ένας διάφορων $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$

ον τέλος διάνομα στο οποίο δίνεται ότι $x_1 = a$. (Κοινή πρέπει
 να εμφανίζονται τα x_2, x_3)

Ορίζουμε λοιπόν $x' = \begin{bmatrix} x_1 \\ x_3 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$

Έτσι ώστε $\mu' = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} = \begin{bmatrix} u_1 \\ u_3 \\ u_2 \end{bmatrix}$

Kαι $\Sigma' = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0,8 & 0,5 \\ 0,8 & 2 & 1 \\ 0,5 & 1 & 3 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}$
 $A \quad \Sigma \quad A^T$ (εδώ $A^T = A$ δόξω
 αυτούς)

Πραγματοποιούμε τώρα την ίδια διαδικασία με το (B) ερώτημα:

$$\hat{\mu}' = \begin{bmatrix} -2 \\ 2 \end{bmatrix} + \begin{bmatrix} 0,8 \\ 1 \end{bmatrix} \cdot 2^{-1} \cdot 1 = \begin{bmatrix} -1,6 \\ 2,5 \end{bmatrix}$$

$$\hat{\Sigma}' = \begin{bmatrix} 1 & 0,5 \\ 0,5 & 3 \end{bmatrix} - \begin{bmatrix} 0,8 \\ 1 \end{bmatrix} \cdot 2^{-1} \cdot \begin{bmatrix} 0,5 & 1 \end{bmatrix} = \begin{bmatrix} 0,8 & 0,1 \\ 0,25 & 2,5 \end{bmatrix}$$

Σχόλιο: Ένας πιο ορθός τρόπος για να περιγράψουμε τη διαδικασία $x' = Ax$ είναι ο όρος «μετασχηματισμός ομοιότητας». Γνωρίζουμε από τη γραμμική άλγεβρα ότι τα eigenvalues και το eigenspace του πίνακα δεν μεταβάλλονται καθώς ο πίνακας A είναι ορθογώνιος, δηλαδή $A^T = A^{-1}$ και τα columns, rows είναι unit vectors. Αυτό ισχύει και για τη διαδικασία $S' = A \Sigma A^T = A \Sigma A^{-1}$, όπου η προηγούμενη σχέση ισχύει αποκλειστικά λόγω της ιδιότητας της ορθογωνιότητας του πίνακα A .

$$p(x_1, x_2 | x_2=1) = \frac{1}{2\pi\sqrt{|\Sigma'|}} \cdot \exp \left\{ -\frac{1}{2} (x - \hat{\mu}') (\hat{\Sigma}')^{-1} (x - \hat{\mu}') \right\}$$

ονού $x = [x_1, x_2]^T$, $\hat{\mu}' = \begin{bmatrix} -1,6 \\ 2,5 \end{bmatrix}$ και $\hat{\Sigma}' = \begin{bmatrix} 0,8 & 0,1 \\ 0,25 & 2,5 \end{bmatrix}$

(8)

μα τι το (6) ερώτημα:

$$(x - \hat{\mu})^T \hat{\Sigma}'^{-1} (x - \hat{\mu}) = c$$

$$\Rightarrow \begin{bmatrix} x_1 + \frac{6,5}{3} & x_2 + \frac{1}{3} \end{bmatrix} \cdot \frac{9}{(2,75 \cdot 5 - 1,9^2)} \begin{bmatrix} \frac{5}{3} & -\frac{1,9}{3} \\ -\frac{1,9}{3} & \frac{2,75}{3} \end{bmatrix} \begin{bmatrix} x_1 + \frac{6,5}{3} \\ x_2 + \frac{1}{3} \end{bmatrix} = c$$

$$\Rightarrow 3 \begin{bmatrix} 5(x_1 + 6,5/3) - 1,9(x_2 + 1/3) & 2,75(x_2 + 1/3) - 1,9(x_1 + 6,5/3) \\ 10,14 & \end{bmatrix} \begin{bmatrix} x_1 + 6,5/3 \\ x_2 + 1/3 \end{bmatrix} = c$$

$$\Rightarrow 3 \begin{bmatrix} 5x_1^2 + 70,4x_1 + 2,75x_2^2 - 6,4x_2 - 3,8x_1x_2 + 63,1 \\ 10,14 \end{bmatrix} = c$$

$$\Rightarrow 15x_1^2 + 61,2x_1 + 8,25x_2^2 - 19,2x_2 - 11,4x_1x_2 + (63,1 - 10,14c) = 0$$

(1)

για το (j) ερώτημα:

$$\begin{bmatrix} x_1+1,6 & x_3-2,5 \end{bmatrix} \begin{bmatrix} 0,8 & 0,1 \\ 0,75 & 7,5 \end{bmatrix}^{-1} \begin{bmatrix} x_1+1,6 \\ x_3-2,5 \end{bmatrix} = c$$

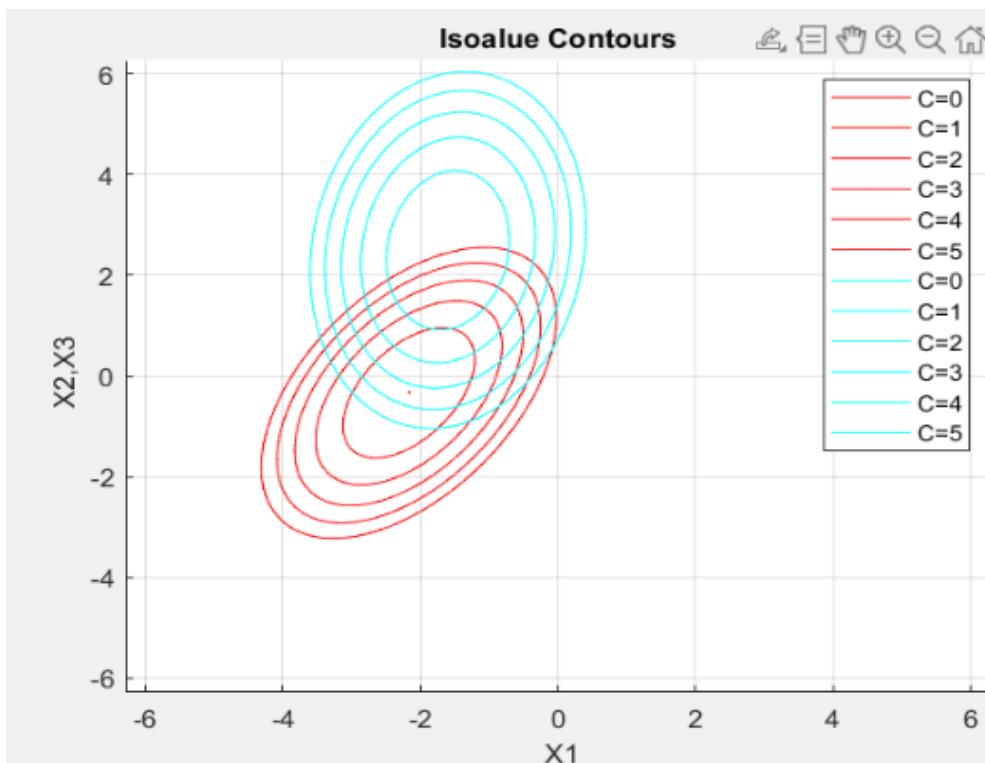
$$\Rightarrow \frac{1}{1,975} [(x_1+1,6)2,5 - 0,1(x_3-2,5) \quad 0,8(x_3-2,5) - 0,75(x_1+1,6)] \begin{bmatrix} x_1+1,6 \\ x_3-2,5 \end{bmatrix} = c$$

$$\Rightarrow 2,5x_1^2 + 0,8x_3^2 + 8,875x_1 - 4,56x_3 - 0,35x_1x_3 + 12,8 - 1,975c = 0$$

(2)

Oι (1) και (2) προσδιορίζουν τις εξιωσιες των ισοσταθμικών καμπύλων.

(δ) Ισοσταθμικές καμπύλες: Για καθένα από τα δύο σύνολα ισοσταθμικών καμπυλών έχει γίνει απεικόνιση με χρήση matlab για τιμές $c = \{0, 1, 2, 3, 4, 5\}$.



Κώδικας (Matlab) που χρησιμοποιήθηκε:

```
clc
clear
close all
%% Define variables & equations
c=0;

Eqn= @(x,y) 15*x.^2 + 61.2*x + 8.25*y.^2 -19.2*y - 11.41*x.*y + 63.1 -
10.14*c ;
c=1;
Eqn1= @(x,y) 15*x.^2 + 61.2*x + 8.25*y.^2 -19.2*y - 11.41*x.*y + 63.1 -
10.14*c ;
c=2;
Eqn2= @(x,y) 15*x.^2 + 61.2*x + 8.25*y.^2 -19.2*y - 11.41*x.*y + 63.1 -
10.14*c ;
c=3;
Eqn3= @(x,y) 15*x.^2 + 61.2*x + 8.25*y.^2 -19.2*y - 11.41*x.*y + 63.1 -
10.14*c ;
c=4;
Eqn4= @(x,y) 15*x.^2 + 61.2*x + 8.25*y.^2 -19.2*y - 11.41*x.*y + 63.1 -
10.14*c ;
c=5;
Eqn5= @(x,y) 15*x.^2 + 61.2*x + 8.25*y.^2 -19.2*y - 11.41*x.*y + 63.1 -
10.14*c ;
c=0;
eqn= @(x1, x2) 2.5*(x1.^2) + 0.8*(x2.^2) + 8.87*x1 - 4.56*x2 -0.35*x1*x2 +
12.8 -1.975*c
c=1;
eqn1= @(x1, x2) 2.5*(x1.^2) + 0.8*(x2.^2) + 8.87*x1 - 4.56*x2 -0.35*x1.*x2
+ 12.8 -1.975*c;
c=2;
eqn2= @(x1, x2) 2.5*(x1.^2) + 0.8*(x2.^2) + 8.87*x1 - 4.56*x2 -0.35*x1.*x2
+ 12.8 -1.975*c;
c=3;
eqn3= @(x1, x2) 2.5*(x1.^2) + 0.8*(x2.^2) + 8.87*x1 - 4.56*x2 -0.35*x1.*x2
+ 12.8 -1.975*c;
c=4;
eqn4= @(x1, x2) 2.5*(x1.^2) + 0.8*(x2.^2) + 8.87*x1 - 4.56*x2 -0.35*x1.*x2
+ 12.8 -1.975*c;
c=5;
eqn5= @(x1, x2) 2.5*(x1.^2) + 0.8*(x2.^2) + 8.87*x1 - 4.56*x2 -0.35*x1.*x2
+ 12.8 -1.975*c
figure
grid on
hold on
b1=ezplot(Eqn);
set(b1,&#39;Color&#39;, &#39;red&#39;,&#39;DisplayName&#39;, &#39;C=0&#39;)
b2=ezplot(Eqn1);
set(b2,&#39;Color&#39;, &#39;red&#39;,&#39;DisplayName&#39;, &#39;C=1&#39;)
b3=ezplot(Eqn2);
set(b3,&#39;Color&#39;, &#39;red&#39;,&#39;DisplayName&#39;, &#39;C=2&#39;)
b4=ezplot(Eqn3);
set(b4,&#39;Color&#39;, &#39;red&#39;,&#39;DisplayName&#39;, &#39;C=3&#39;)
b5=ezplot(Eqn4);
set(b5,&#39;Color&#39;, &#39;red&#39;,&#39;DisplayName&#39;, &#39;C=4&#39;)
```

```
b6=ezplot(Eqn5);
set(b6,&#39;Color&#39;, &#39;red&#39;, &#39;DisplayName&#39;, &#39;C=5&#39;)
c1=ezplot(eqn);
set(c1,&#39;Color&#39;, &#39;cyan&#39;, &#39;DisplayName&#39;, &#39;C=0&#39;)
c2=ezplot(eqn1);
set(c2,&#39;Color&#39;, &#39;cyan&#39;, &#39;DisplayName&#39;, &#39;C=1&#39;)
c3=ezplot(eqn2);
set(c3,&#39;Color&#39;, &#39;cyan&#39;, &#39;DisplayName&#39;, &#39;C=2&#39;)
c4=ezplot(eqn3);
set(c4,&#39;Color&#39;, &#39;cyan&#39;, &#39;DisplayName&#39;, &#39;C=3&#39;)
c5=ezplot(eqn4);

set(c5,&#39;Color&#39;, &#39;cyan&#39;, &#39;DisplayName&#39;, &#39;C=4&#39;)
c6=ezplot(eqn5);
set(c6,&#39;Color&#39;, &#39;cyan&#39;, &#39;DisplayName&#39;, &#39;C=5&#39;)
title(&#39;Isoalue Contours&#39;)
xlabel(&#39; X1&#39;)
ylabel(&#39; X2,X3&#39;)
legend(&#39;show&#39;)
```

Άσκηση 1.3 (Bayes classifier)

Άσκηση 1.3 (Bayes classifier)

$$p(w_1) = p(w_2)$$

$$p(x|w_1), p(x|w_2) : \text{Gaussian} \quad \mu_1 = [-2, 0]^T \\ \mu_2 = [2, 1]^T$$

(a) κοινό $\Sigma = I_2$

$$\Rightarrow \Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Αντί στη σελ. 27 των slides του μαθήματος παραπομπή για το decision boundary:

$$g(x) = \frac{1}{2} (x^T \Sigma^{-1} x - x^T \Sigma^{-1} \mu_1 + \mu_1^T \Sigma^{-1} x - \frac{1}{2} \mu_1^T \Sigma^{-1} \mu_1 + \frac{1}{2} \mu_2^T \Sigma^{-1} \mu_2)$$

$$+ \ln p(w_1) + \frac{1}{2} \ln |\Sigma| = 0$$

το ονομάζουμε του κοινού ρυθμού Σ και επειδή $p(w_1) = p(w_2)$
γινεται: $\frac{\mu_1^T = \mu_2^T}{\mu_1^T = \mu_2^T} (x^T - \frac{1}{2} (\mu_1^T \mu_1 - \mu_2^T \mu_2)) = 0$

$$\Rightarrow g(x) = [-4 \ -1] x - \frac{1}{2} (4 - 5) = 0$$

$$\Rightarrow g(x) = -4x_1 - x_2 + \frac{1}{2} = 0$$

Δηλαδή η βέτανη ευθεία απόφασης είναι έξιν με τις

$$8x_1 + 2x_2 - 1 = 0$$

$$(b) \text{ Kovó } \hat{\Sigma} = \begin{bmatrix} 1 & -0,6 \\ -0,6 & 1 \end{bmatrix}$$

$$\text{όποιως, } g(x) = (\mu_1^\top - \mu_2^\top) \hat{\Sigma}^{-1} x - \frac{1}{2} (\mu_1^\top \hat{\Sigma}^{-1} \mu_1 - \mu_2^\top \hat{\Sigma}^{-1} \mu_2) = 0$$

$$\text{όπου } \hat{\Sigma}^{-1} = \begin{bmatrix} 1 & -0,6 \\ -0,6 & 1 \end{bmatrix} = \frac{1}{1-0,36} \begin{bmatrix} 1 & 0,6 \\ 0,6 & 1 \end{bmatrix} = \begin{bmatrix} 1,5625 & 0,9375 \\ 0,9375 & 1,5625 \end{bmatrix}$$

$$g(x) = [-7,1875 \quad -5,3125] x - \frac{1}{2} \begin{bmatrix} [-3,125 \quad -1,875] \\ [0] \end{bmatrix} \begin{bmatrix} [-2] \\ [1] \end{bmatrix} - [4,0625 \quad 3,4375] \begin{bmatrix} [2] \\ [1] \end{bmatrix}$$

$$\Rightarrow g(x) = -7,1875x_1 - 5,3125x_2 - \frac{1}{2} (-6,75 - (11,5625)) = 0$$

$$\Rightarrow g(x) = -7,1875x_1 - 5,3125x_2 + 8,90625 = 0$$

Η δέσμην των ευδελα ανάφορς είναι σταθμ με εξίσωση

$$7,1875x_1 + 5,3125x_2 - 8,90625 = 0$$

$$(f) \text{ Kovó } \hat{\Sigma}, \lambda_{12} = 1 \text{ και } \lambda_{21} = 1/2$$

To decision boundary ενδέχεται να γίνει ως:

$$\ln(\lambda_{12} p(x|w_1)) = \ln(\lambda_{21} p(x|w_2)) \Rightarrow \ln(p(x|w_1)) = \ln(0,5 p(x|w_2))$$

$$\Rightarrow \ln(p(x|w_1)) = \ln(0,5) + \ln(p(x|w_2))$$

όπως η εξίσωση $\ln(p(x|w_1)) = \ln(p(x|w_2))$ δεν είναι παρά η $g(x)$ του (b) εργαζόμενος.

$$\text{Συντομούσ } \hat{\Sigma} \text{ όπου: } -7,1875x_1 - 5,3125x_2 + 8,90625 = -0,69314 = g(x)$$

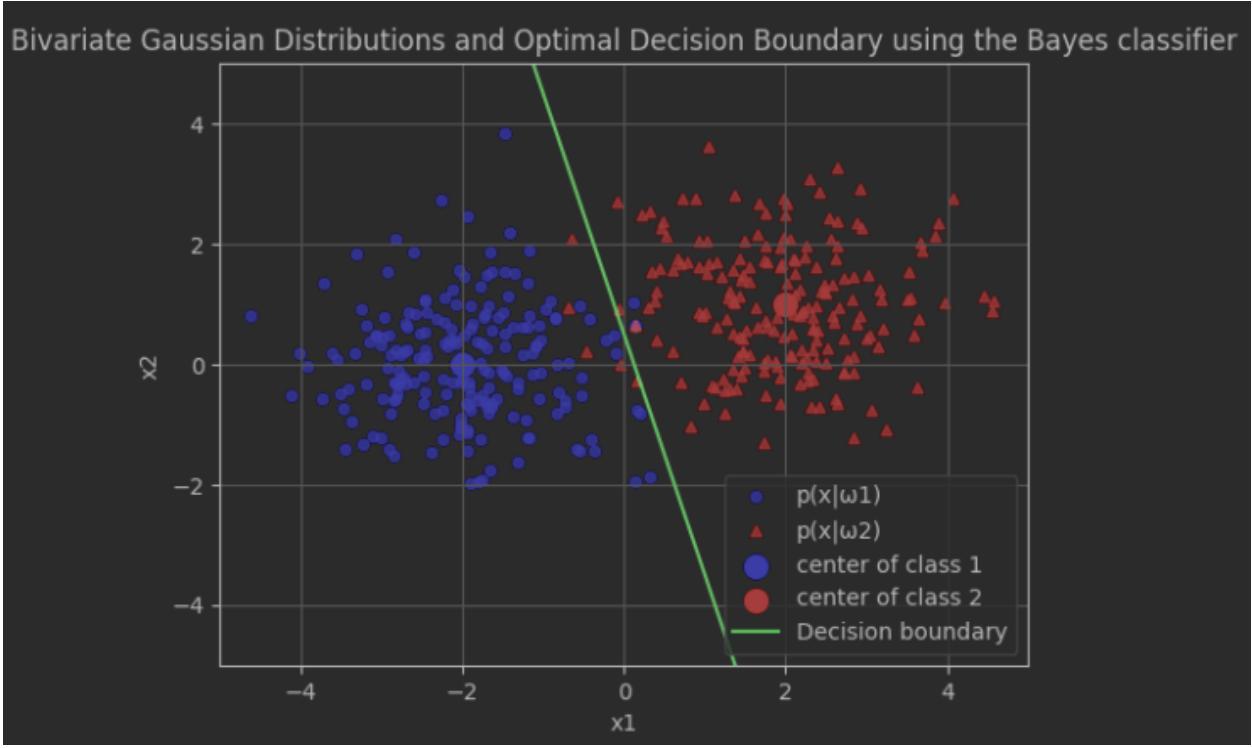
$$\Rightarrow g(x) = -7,1875x_1 - 5,3125x_2 + 9,6 = 0$$

Η δέσμην των ευδελα ανάφορς είναι σταθμ με εξίσωση

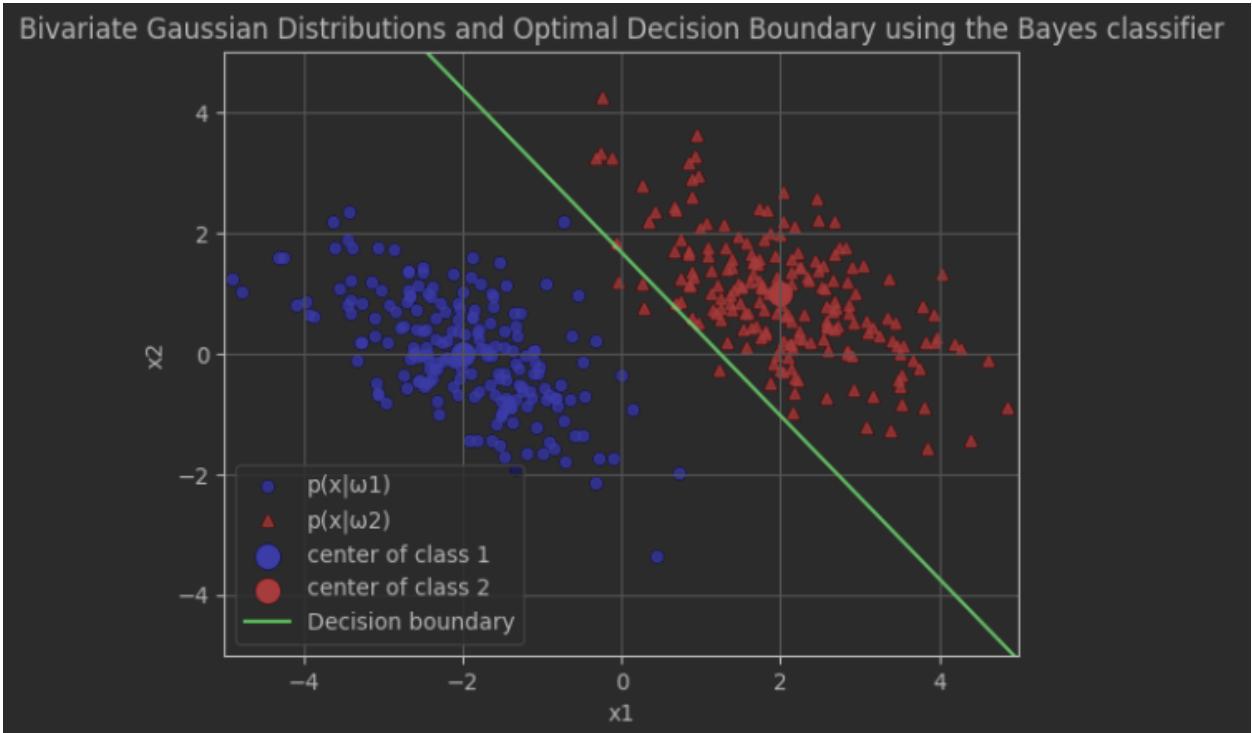
$$7,1875x_1 + 5,3125x_2 - 9,6 = 0$$

(δ)

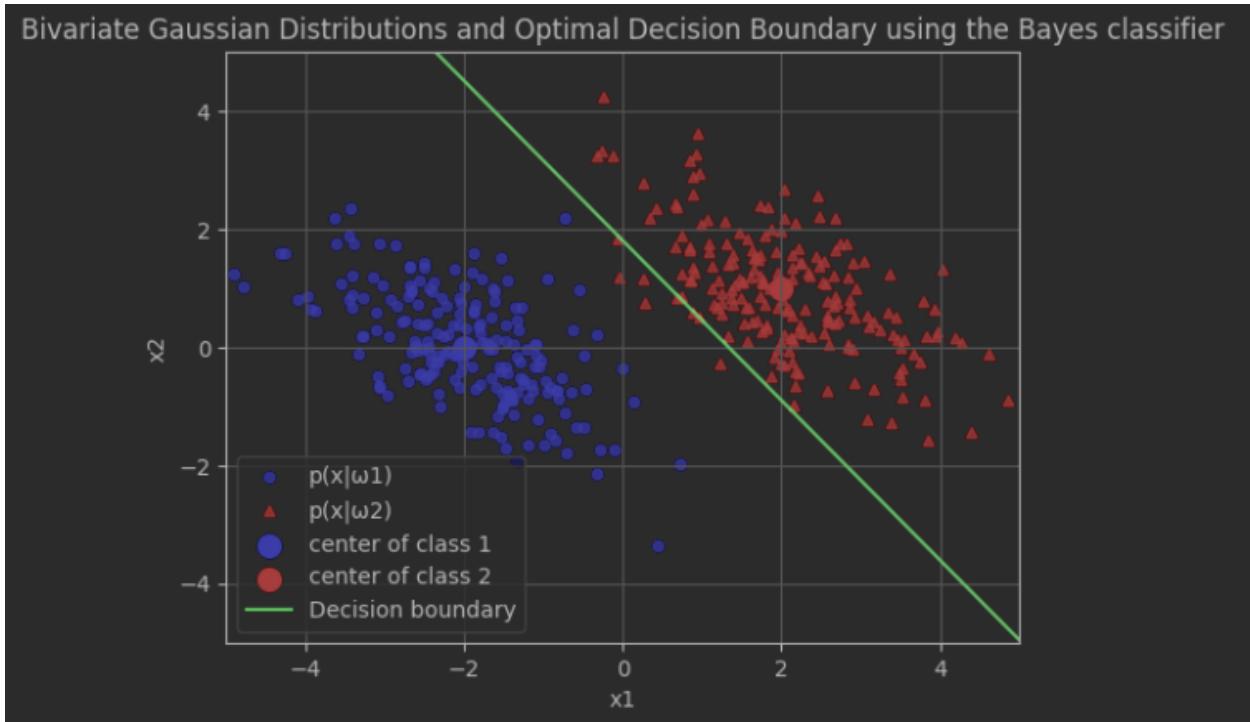
για το (α) ερώτημα:



για το (β) ερώτημα:



για το (γ) ερώτημα:



Κώδικας (Python) που χρησιμοποιήθηκε:

```
import numpy as np
import matplotlib.pyplot as plt

# Set seed for reproducibility
np.random.seed(42)

# Parameters for the first distribution
mu1 = np.array([-2, 0])
cov1 = np.array([[1, 0], [0, 1]])

# Parameters for the second distribution
mu2 = np.array([2, 1])
cov2 = np.array([[1, 0], [0, 1]])

# Number of points to generate for each distribution
num_points = 200

# Generate points for the first distribution
points1 = np.random.multivariate_normal(mu1, cov1, num_points)
```

```

# Generate points for the second distribution
points2 = np.random.multivariate_normal(mu2, cov2, num_points)

# Plot the points for the first distribution
plt.scatter(points1[:, 0], points1[:, 1], label='p(x|ω1)', alpha=0.7, c='b',
marker='o', s=20)

# Plot the points for the second distribution
plt.scatter(points2[:, 0], points2[:, 1], label='p(x|ω2)', alpha=0.7, c='r',
marker='^', s=20)

# Plot the means as red points
plt.scatter(mu1[0], mu1[1], color='blue', marker='o', label='center of class
1', s=100)
plt.scatter(mu2[0], mu2[1], color='red', marker='o', label='center of class
2', s=100)

# Plot the decision boundary line
x_line = np.linspace(-5, 5, 100)
y_line = (1 - 8 * x_line) / 2
plt.plot(x_line, y_line, color='green', label='Decision boundary')

# Set labels and title
plt.xlabel('x1')
plt.ylabel('x2')
plt.title('Bivariate Gaussian Distributions and Optimal Decision Boundary
using the Bayes classifier')

# Add legend
plt.legend()

# Set limits to zoom in
plt.xlim([-5, 5])
plt.ylim([-5, 5])

# Show the plot
plt.grid(True)
plt.show()

```

Το παραπάνω code cell αντιστοιχεί στο πρώτο plot, προφανώς ο κώδικας για τα άλλα 2 είναι ακριβώς ο ίδιος με μοναδική διαφορά στα:

```

y_line = (8.90625 - 7.1875 * x_line) / 5.3125. και
y_line = (9.6 - 7.1875 * x_line) / 5.3125 αντίστοιχα.

```

Σχόλια: Παρατηρούμε ότι τα decision boundaries είναι και στις 3 περιπτώσεις ευθείες. Αυτό συμβαίνει διότι ο πίνακας συνδιακύμανσης είναι κοινός και ως αποτέλεσμα η εξίσωση $g(x)$ δεν περιέχει quadratic terms. Ακόμα, η υπερεπιφάνεια απόφασης στο (y) ερώτημα δεν είναι παρά μια μετατοπισμένη μορφή εκείνης του (β) ερωτήματος: μας έχουν δοθεί τα λ_{12} και λ_{21} με $\lambda_{12} > \lambda_{21}$, το οποίο σημαίνει ότι η κλάση ω_1 είναι πιο «σημαντική», άρα πρέπει να αυξήσουμε τον σταθερό όρο της ευθείας, ώστε να μεγαλώσουμε την περιοχή στην οποία αποφασίζουμε υπέρ της πιο σημαντικής κλάσης ω_1 .

Άσκηση 4 (Perceptron - MultiLayer Perceptron)

'Άσκηση 14. (Perceptron - MultiLayer Perceptron)

(a) activation function: step function

$$\vec{w} = [1, 0, 0, 0] \quad , \quad y = [0, 1, 1, 0]$$

$$\text{και } X = \left[\begin{matrix} \begin{bmatrix} 1 \\ 4 \\ 3 \\ 6 \end{bmatrix}, \begin{bmatrix} 1 \\ 2 \\ -2 \\ 3 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 0 \\ -3 \end{bmatrix}, \begin{bmatrix} 1 \\ 4 \\ 2 \\ 3 \end{bmatrix} \end{matrix} \right]$$

Εκπαίδωση σύμφωνα με $w_i \rightarrow w_i + n(y - \hat{y}) \cdot x_{(i)}$, $i \in \{0, 1, 2, 3\}$

$n=1$ (training step), δηλαδή $w \leftarrow (y - \hat{y})x$,

$\hat{y}_i = f(\vec{w}_i \cdot \vec{x}_{(i)})$, εδώ f =activation function: step function

οντας $f(\cdot) = u(\cdot)$

1^ο iteration:

$$\hat{y} = u(\vec{w} \cdot \vec{x}_{(0)}) = u(1) = 1 \quad \text{FP}$$

$$\vec{w}^+ = (y - \hat{y}) \cdot \vec{x}_{(0)} = [1 \ 0 \ 0 \ 0] + (0-1)[1 \ 4 \ 3 \ 6] = [0 \ -4 \ -3 \ -6]$$

$$\hat{y} = u(\vec{w} \cdot \vec{x}_{(1)}) = u([0 \ -4 \ -3 \ -6] \cdot [1 \ 2 \ -2 \ 3]^T) = u(-19) = 0 \quad \text{TN}$$

$$\vec{w}^+ = (y - \hat{y}) \cdot \vec{x}_{(1)} = [0 \ -4 \ -3 \ 6] + (1-0)[1 \ 2 \ -2 \ 3] = [1 \ -2 \ -5 \ 9]$$

$$\hat{y} = u(\vec{w} \cdot \vec{x}_{(2)}) = u([1 \ -2 \ -5 \ 9] \cdot [1 \ 1 \ 0 \ -3]^T) = u(-28) = 0 \quad \text{TN}$$

$$\vec{w}^+ = (y - \hat{y}) \cdot \vec{x}_{(2)} = [1 \ -2 \ -5 \ 9] + [1 \ 1 \ 0 \ -3] = [2 \ -1 \ -5 \ -6]$$

$$\hat{y} = u(\vec{w} \cdot \vec{x}_{(3)}) = u([2 \ -1 \ -5 \ 6] \cdot [1 \ 4 \ 2 \ 3]^T) = u(6) = 1 \quad \text{FP}$$

$$\vec{w}^+ = (y - \hat{y}) \cdot \vec{x}_{(3)} = [2 \ -1 \ -5 \ 6] - [1 \ 4 \ 2 \ 3] = [1 \ -5 \ -7 \ 3]$$

2^o iteration:

$$\hat{y} = u(\vec{w} \times [0]) = u([1 -5 -7 3] [1 4 3 6]^T) = u(-22) = 0 \quad \text{FN}$$

$$\hat{y} = u(\vec{w} \times [1]) = u([1 -5 -7 3] [1 2 -2 3]^T) = u(14) = 1 \quad \text{TP}$$

$$\hat{y} = u(\vec{w} \times [2]) = u([1 -5 -7 3] [1 1 0 -3]^T) = u(-13) = 0 \quad \text{TN}$$

$$\vec{w} = [1 -5 -7 3] + [1 1 0 -3] = [2 -4 -7 0]$$

$$\hat{y} = u(\vec{w} \times [3]) = u([2 -4 -7 0] [1 4 2 3]^T) = u(-32) = 0 \quad \text{FN}$$

3^o iteration:

$$\hat{y} = u(\vec{w} \times [0]) = u([2 -4 -7 0] [1 4 3 6]^T) = u(-25) = 0 \quad \text{FN}$$

$$\hat{y} = u(\vec{w} \times [1]) = u([2 -4 -7 0] [1 2 -2 3]^T) = u(8) = 1 \quad \text{TP}$$

$$\hat{y} = u(\vec{w} \times [2]) = u([2 -4 -7 0] [1 1 0 -3]^T) = u(-2) = 0 \quad \text{TN}$$

$$\vec{w} = [2 -4 -7 0] + [1 1 0 -3] = [3 -3 -7 3]$$

$$\hat{y} = u(\vec{w} \times [3]) = u([3 -3 -7 3] [1 4 2 3]^T) = u(-14) = 0 \quad \text{FN}$$

4^o iteration:

$$\hat{y} = u(\vec{w} \times [0]) = u([3 -3 -7 3] [1 4 3 6]^T) = u(-12) = 0 \quad \text{FN}$$

$$\hat{y} = u([3 -3 -7 3] [1 2 -2 3]^T) = u(11) = 1 \quad \text{TP}$$

$$\hat{y} = u([3 -3 -7 3] [1 1 0 3]^T) = u(9) = 1 \quad \text{TP}$$

$$\hat{y} = u([3 -3 -7 3] [1 4 2 3]^T) = u(-14) = 0 \quad \text{FN}$$

αριθμός επιχειρήσεων = εξόδος φάσας σε convergence, το οποίο γίνεται σε $4 \cdot 4 = 16$ βήματα

Έχουμε μηδημια διαχυτική απόσταση στην οποίαν πρέπει να γίνεται η επόμενη update (iteration). Και είναι αυτό πραγματεύεται στην μορφή
 $k \leq \frac{R^2}{\gamma^2}$, όπου $y_n x_n^T w^* \geq \gamma$ και $\|x_n\| \leq R$

(β) Για την εκβολή των επικενδίων \mathbb{R}^2 έχουμε:

Για το χωρίο στο οποίο $x \in C_p$: $f(x) \in C_p \Leftrightarrow x_1 \geq 2 \text{ OR } x_2 \geq 3$
(δύο ευθείες)

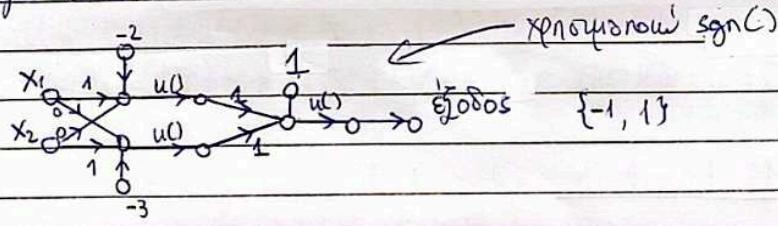
Οι 2 πρώτοι (παραλλήλοι) perceptrons έχουν $p_1: (-2, 1, 0)$

και $p_2: (3, 0, 1)$

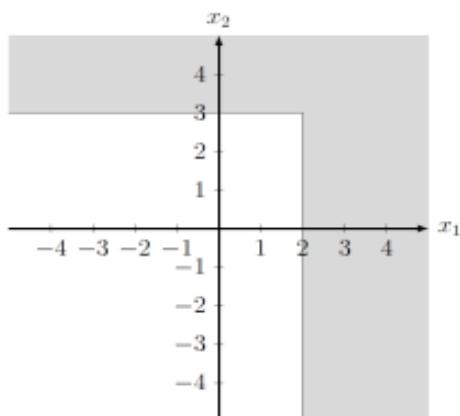
Ο p_3 αποδεικνύει ότι τους παραπάνω p_1, p_2 με λογική AND,

απαντά $p_3: (1, 1, 1)$

Τοπολογία δικτύων



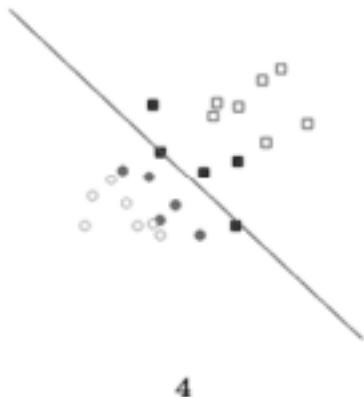
Εικόνα (β) ερωτήματος:



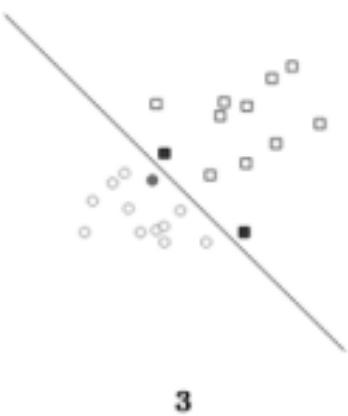
Άσκηση 1.5 (Support Vector Machines – Kernels)

Η αντιστοίχιση γίνεται ως εξής:

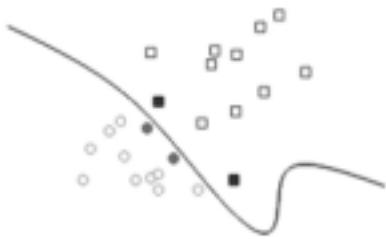
(α) → 4 : έχουμε να επιλέξουμε ανάμεσα σε 2 linear SVMs (3 και 4). Αναμένουμε με μικρότερη τιμή C να έχουμε περισσότερα misclassifications και μεγαλύτερο margin, γι' αυτό επιλέγουμε το διάγραμμα 4. Παρατηρούμε επίσης περισσότερα support vectors.



(β) → 3 : το μοναδικό άλλο linear SVM. Έχει μικρότερο tolerance σε misclassifications καθώς έχει μεγαλύτερη τιμή C αλλά και μικρότερο margin.

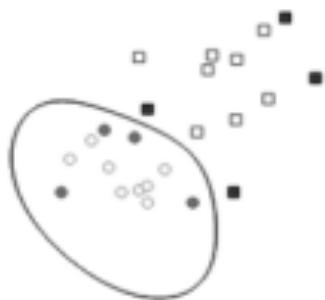


(γ) → 2 : αντιστοιχεί σε ένα πολυώνυμο 2^{ου} βαθμού λόγω του όρου $(u^T v)^2$ και δεν μπορεί να αναπαραστήσει υπερβολή (διάγραμμα 5) ή μια εκ των κλειστών καμπύλων όπως έχουν τα διαγράμματα 1 και 6. Το πολυώνυμο 2^{ου} βαθμού αντιστοιχεί λοιπόν στο διάγραμμα 2.



2

(δ) → 1 : υπάρχουν 2 διαγράμματα που αντιστοιχούν σε RBF: τα διαγράμματα 1 και 6 τα οποία διαφέρουν αποκλειστικά ως προς την παράμετρο γ. Συγκεκριμένα γνωρίζουμε ότι μεγαλύτερη τιμή της παραμέτρου γ αντιστοιχεί σε πιο «στενό» και περίπλοκο decision boundary, οπότε για τιμή γ = 0.25 επιλέγουμε το διάγραμμα 1.



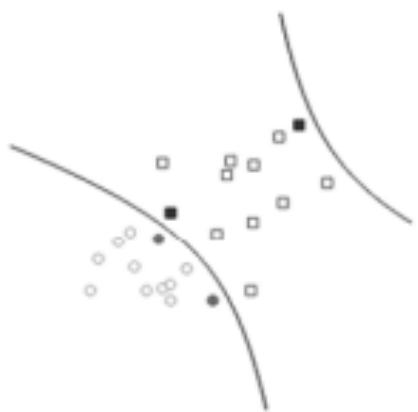
1

(ε) → 6 : με βάση το παραπάνω επιχείρημα επιλέγουμε το διάγραμμα 6.



6

(στ) → 5 : κανένα από τα υποψήφια SVMs δεν μπορεί να αναπαραστήσει το συγκεκριμένο decision boundary (υπερβολή).



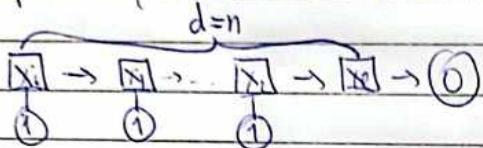
5

Άσκηση 1.6 (Decision Trees)

'Άσκηση 1.6 (Decision Trees)

(a) 1. x : vector k Boolean $x_1/x_2 \dots x_n$
 fn classifier πεδίων n $x_1/x_2 \dots x_n$.

depth δύπου d τούλαξιτον n :



δερμάτις το δύπο $\rightarrow h_d: \{0,1\}^d \rightarrow \{0,1\}$
 Αναμφίβολη τύπα τα εξής:

- $d \leq n$: συδετέμενη im(h_d) \subset im(fn) και αναποτελεί σημείο νεφιλώματος σχηματικά: x not in h \wedge x δείνει ανά το fn (αδιάτυπη η ανεύθυνη του fn)

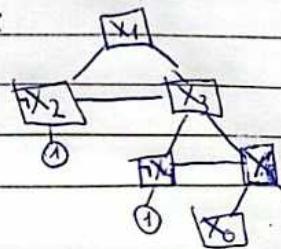
- $d > n$ ή $dom(fn) \subset dom(h_d)$: τότε νέα νόμημα αφθοδίας
 $im(f_n) \subseteq im(h_d)$

2. fn εργάζεται με ένα διατύπως αριθμόν της αριθμού τους.
 (unique appearance)

Θα σχεδιάσουμε το δύπο με την εξής ιδέα:

- διατύπως \rightarrow κανόνες που πρέπει να φύγει
 Οι εκ των των περιον, ανόρθως ανά κάθε κόμβο οι φύγοι είναι ? Δηλαδή (x_i):

$$fn = (x_1 \wedge \neg x_2) \vee (x_2 \wedge \neg x_4) \\ \vee (x_5 \wedge x_6)$$



(b)

1. Μερικής Gini:

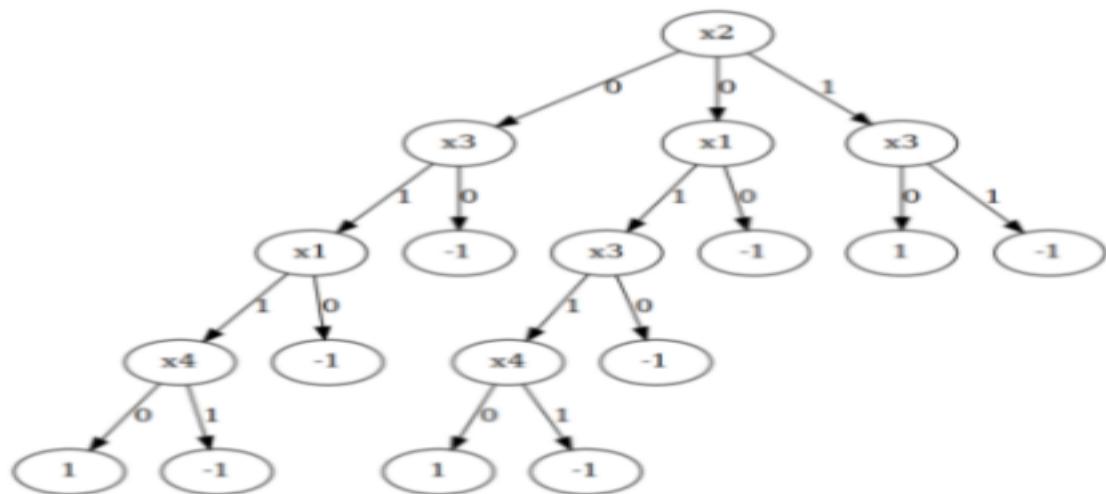
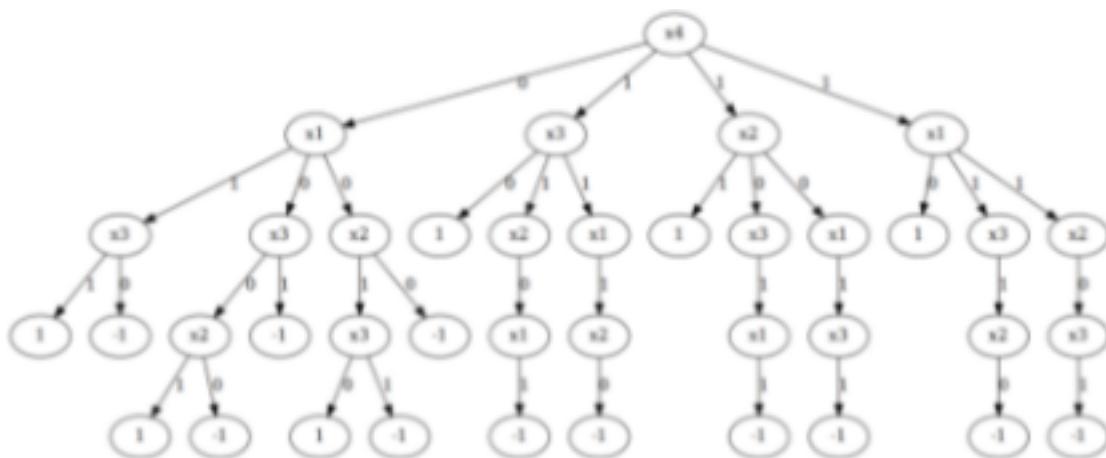
Χρησιμοποιείται για να αναπληρώσει τα λεύκανα στη διάταξη:

$$gini(\text{Root}) = 1 - \frac{(y=1)^2}{10} - \frac{(y=0)^2}{10}$$

$$gini(\text{other}) = \frac{|\text{other}=0|}{|\text{Root}|} gini(\text{other}=0) + \frac{|\text{other}=1|}{|\text{Root}|} gini(\text{other}=1)$$

$$\text{best_attr} = \underset{\text{other in attr}}{\operatorname{argmax}} \{ gini(\text{Root}) - gini(\text{other}) \}$$

Κατά παράδειγμα για την επέκταση της δέντρου:



Mε οριζόντιο Fairness: Οι γνωστοί $E = \sum -p_i \log_2 p_i$

$$E(\text{Root}) = -\frac{5}{10} \log_2 \left(\frac{5}{10}\right) \cdot 2 = 1 \quad E(x_1) = -\frac{5}{10} \cdot \log_2 \left(\frac{5}{10}\right) \cdot 2 = 1$$

$$E(x_2) = -\frac{3}{10} \log_2 \left(\frac{3}{10}\right) - \frac{7}{10} \log_2 \left(\frac{7}{10}\right) = 0,88$$

$$E(x_3) = -\frac{6}{10} \log_2 \left(\frac{6}{10}\right) - \frac{4}{10} \log_2 \left(\frac{4}{10}\right) = 0,97$$

$$E(x_4) = 0,83$$

$$i_g(x_1) = E(\text{Root}) - E(x_1) \cdot 5/10 = 0,5 \quad i_g(x_2) = E(\text{Root}) - E(x_2) \cdot 3/10 = 0,74$$

$$i_g(x_3) = E(\text{Root}) - E(x_3) \cdot 6/10 = 0,42 \quad i_g(x_4) = E(\text{Root}) - E(x_4) \cdot 3/10 = 0,74$$

Ενδιέγουμε αναλύστρα των x_i (διαφορούσαν και τα x_4)

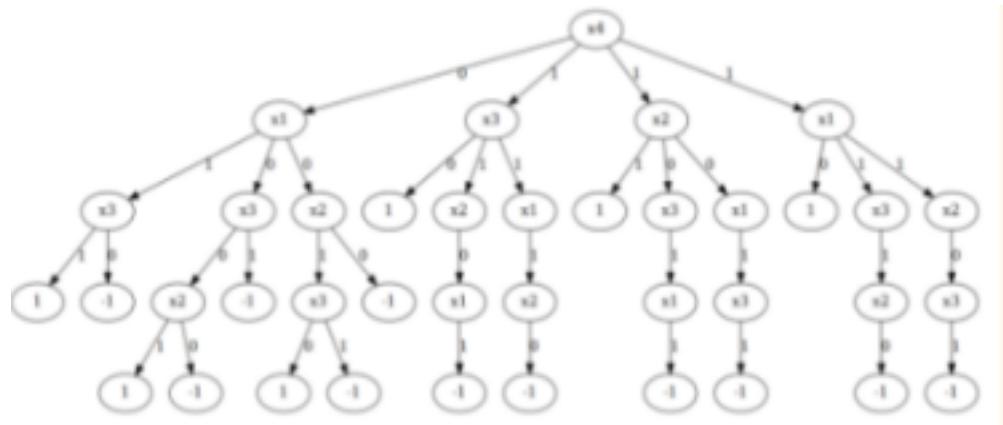
Αποτελέσματα: $\#(x_1=0) = 7$,

$$E(x_1) = -\frac{5}{7} \left(\frac{5}{7} \log_2 \frac{5}{7} + \frac{2}{7} \log_2 \frac{2}{7} \right) = 0,61$$

$$E(x_3) = -\frac{5}{7} \left(\frac{5}{7} \log_2 \frac{5}{7} + \frac{2}{7} \log_2 \frac{2}{7} \right) = 0,61$$

$$E(x_4) = -\frac{2}{7} \left(\frac{5}{7} \log_2 \frac{5}{7} + \frac{2}{7} \log_2 \frac{2}{7} \right) = 0,246$$

Συμπληρώνεται ότι τα δύο τρόποι ενδιέγυρες τα x_4 και αποκατέλουν τα παρακάτω



2.

Τα βέλτιστα , ως προς την ακρίβεια, δέντρα απόφασης, αν έχουμε τον επιπλέον περιορισμό ότι το δέντρο πρέπει να έχει ύψος το πολύ 2 αντιστοιχούν στα δέντρα που έχουν ως ρίζες τους κόμβους που βρίσκονται σε ύψος 1 στις εικόνες.

3.

Προφανώς ένας αποδοτικός αλγόριθμος για τον ζητούμενο υπολογισμό θα ήταν δύσκολο να επινοηθεί για οποιοδήποτε dataset και για οποιουδήποτε ύψους δέντρα (σίγουρα με τις γνώσεις που έως τώρα διαθέτουμε).

Μια καλή πρακτική είναι γενικά το κλάδεμα, όπως και μικρός (ελάχιστος) αριθμός φύλλων και samples για split. Θα μπορούσαμε ακόμα, υπό κάποιες προϋποθέσεις να αντικαταστήσουμε συγκεκριμένους κόμβους (ίσως από έναν αριθμό από κλαδέματα και μετά) με την πιο συχνή κλάση, ή με μία κλάση που πληρεί -ανάλογα με το dataset- συγκεκριμένες διαφορετικές προδιαγραφές πέρα από τη συχνότητα (πχ class distribution σε διάφορα features, feature importance κλπ)

Οι παρατηρήσεις που χρησιμοποιήθηκαν στο (β) ερώτημα (χαρακτηριστικά και κλάση ταξινόμησης):

x_1	x_2	x_3	x_4	y
1	0	1	0	1
0	1	0	1	1
1	0	1	0	1
1	0	1	1	1
0	1	0	0	1
1	0	1	1	-1
0	1	1	0	-1
0	0	0	0	-1
0	0	1	0	-1
1	0	0	0	-1